

## گزارش پروژه تمرین سری دوم بخش دوم

### اشکان ودادی گرگری

9713032

#### چکیده مطالب:

کد نوشته شده چهار بخش دارد و دو بخش نیز مربوط به گزارش است که هر بخش را به طور کامل توضیح خواهیم داد.

1. کلاس گراف
2. گرفتن فایل متنی از input.txt
3. اجرای الگوریتم ژنتیک
  - a. مقداردهی اولیه
  - b. تابع هدف
  - c. حلقه اصلی
  - d. الگوریتم cross over
  - e. الگوریتم mutation
4. نمودار همگرایی
5. چند نمونه خروجی
6. مقایسه با الگوریتم SA

#### بخش اول - کلاس گراف:

- زنجیره ارتباطاتی که در txt به ما میدهند با کمک کلاس گراف به صورت یک لیست مجاورت نگهداری می‌کنیم.
- در این بخش یک کلاس طراحی کردیم که بتوانیم اطلاعاتمون رو به صورت گراف ذخیره کنیم. برای این ذخیره سازی از لیست مجاورت استفاده کردیم.
- خود گراف را در graph نگهداری می‌کند که یک دیکشنری از لیست است.
- این کلاس مجموعه راس‌های گراف را در V ذخیره میکند.
- مقدار یال‌های گراف را به صورت e نگه داری میکنیم و در هر مرحله اضافه کردن هر یال یکی بهش اضافه می‌شود.

```
class Graph:
    def __init__(self,v):
        self.v = v
        self.e = 0
        self.graph = defaultdict(list)
```

- متد addEdge() برای این است که به مجموعه رئوسمون یال اضافه کنیم. علاوه بر اضافه شدن یال به تعداد یال‌های گراف نیز یکی اضافه می‌کند.
- متد printGraph() برای این است که تابع گرافمان را چاپ کنیم.

- متد isReachable(a,b) برای این است چک می‌کند که آیا از a به b مسیر است یا نه؟ (آیا a شکارچی b است). این متد با کمک BFS پیامش میکند و مسیر را پیدا می‌کند.
- متدهای DFS و DFSUtil نیز متدهای مربوط به DFS گراف است که البته در الگوریتم استفاده نشده است.

```
class Graph:
    def __init__(self,v):
        self.v = v
        self.e = 0
        self.graph = defaultdict(list)

    def addEdge(self, s, d):
        self.graph[s].append(d)
        self.e = self.e + 1

    def isReachable(self,src,dest):
        visited =[False]*(self.v+1)

        queue=[]
        queue.append(src)

        visited[src] = True
        while queue:
            n = queue.pop(0)
            if n == dest:
                return True
            for i in self.graph[n]:
                if visited[i] == False:
                    queue.append(i)
                    visited[i] = True
        return False

    def printGraph(self):
        for i in range(self.v):
            print("src=",i)
            for j in self.graph[i]:
                print(j)

    def DFSUtil(self, v, visited):
        visited.add(v)
        print(v, end=' ')
        for j in self.graph[v]:
            if j not in visited:
                self.DFSUtil(j, visited)
```

```
def DFS(self, v):
    visited = set()
    self.DFSUtil(v, visited)
```

### بخش دوم - گرفتن فایل متنی از input.txt:

- در این بخش فایل ورودی را میخوانیم.
- File\_address همان آدرس فایل متنی ما است
- Lines خطوط فایل را در آن‌ها قرار می‌دهیم. که خط اول فایل همان تعداد راس‌های گرافمان است. و سایر خطوط را نیز با addEdge به گراف اضافه می‌کنیم.

```
# GET INPUT FUNCTION and COVERT TO GRAPH
file_address = "C:/Users/Ashkan/Desktop/Term 8/بخش اول/تمرین 2- تمرین ها/هوش/SA/input.txt"

lines = []
with open(file_address) as f:
    lines = f.readlines() # har khato mirize to y khune array

V = int(lines[0])
graph = Graph(V+1)
count = 0
for line in lines:
    if(count!=0):
        edge = line.split(' ')
        graph.addEdge(int(edge[0]),int(edge[1]))
    count += 1
```

### بخش سوم - اجرای الگوریتم ژنتیک:

#### 1. مقداردهی اولیه:

- مقدارهای اولیه شروع الگوریتم را در این قسمت مقداردهی می‌کنیم.
- N تعداد حیوانات (راس‌های گراف) است. در الگوریتم نیز اندازه آرایه جواب قرار است باشد.
- Population\_size اندازه آغازی جمعیت است.
- Max\_pop\_size اندازه حداکثری جامعه است.
- Crossover\_coeff ضریبی از جمعیت که روی آن‌ها عملیات cross\_over انجام می‌شود.
- Mutation\_coeff ضریبی از جمعیت که روی آن‌ها عملیات جهش انجام می‌شود.
- Max\_iteration حداکثر تعداد دفعاتی که حلقه تکرار می‌شود.

```
# INITIAL
n = V
population_size = 200
max_pop_size = 600
crossover_coeff = 0.7
mutation_coeff = 0.04
max_iteration = 500
```

- Num\_crossover تعداد اعضای از جمعیت که crossover انجام میشود.
- Num\_mutation تعداد اعضای از جمعیت که جهش روی آن انجام می‌شود.

```
num_crossover = round(population_size * crossover_coeff)
num_mutation = round(population_size * mutation_coeff)
total = population_size + num_crossover + num_mutation
```

- Population اعضای جمعیت را نگه میدارد.
- Object\_values مقدار تابع هدف هر عضو جامعه را نگه میدارد.
- Best\_objectives مقدار ماکسimum تابع هدف در کل جمعیت است.
- Best\_chromosome خود عضوی که تابع هدف بهینه برای آن است.

```
population = []
object_values = []
best_objectives = 0
best_chromosome = np.zeros(n)
```

- حلقه تولید k جمعیت اولیه به این صورت است که تا زمانی که population به اندازه جمعیت اولیه بشود چیش تصادفی تولید می‌کند و به population اضافه می‌کند و همچنین مقدار بهینش را به object\_values اضافه می‌کند.

```
# INITAIL K Population
while len(population) < population_size:
    sequence = [i for i in range(1,n+1)]
    solution = random.sample(sequence, n)
    population.append(solution.copy())
    object_values.append(objective(solution))
```

## 2. تابع هدف:

- تابع هدف مسئله به این صورت است که تعداد ترتیب‌های نادرست را می‌شماریم. روش این کار نیز به این صورت است که لیستی از ترتیب هر گره داریم و چک میکنیم آیا مسیر وجود دارد یا نه؟ اگر مسیر وجود داشت ولی جاشون برعکس بود یک واحد به q اضافه میکند. اما در نهایت q را از مقدار پال‌ها کم می‌کنیم. در نهایت هدف ما این است به تعداد پال‌های گراف برسیم.

```
def objective(sol):
```

```

q = 0
for i in range(n):
    for j in range(i,n):
        if(graph.isReachable(sol[j],sol[i]) and i!=j):
            q = q + 1
return graph.e-q

```

### 3. حلقه اصلی:

- بدنه اصلی الگوریتم بعد مقدار دهی اولی اینجا انجام می‌شود.
- مشابه کدی که در کلاس کارگاه زده شد.
- تا زمانی که تعداد iteration ها از تعداد کل max\_iteration کمتر باشد حلقه انجام می‌شود.
- بخش cross over و mutation را در ادامه به طور دقیق توضیح می‌دهم.
- در آخر هر جهش و cross over ، بهترین عضو جمعیت را بر اساس مقدار تابع هدف آن پیدا می‌کنیم و در best\_objective ذخیره می‌کنیم و اندیس آن را در best\_arg و خودش را در best\_chromosome ذخیره می‌کنیم.
- همچنین اگر در یک مرحله از تولید مثل و جهش تعداد اعضای حاصل از ماکسیموم جمعیت جامعه بیشتر باشد ابتدا تمام اعضا را بر اساس مقدار تابع هدف مرتب می‌کنیم و به تعداد max\_pop\_size نگه می‌داریم و باقی را دور می‌ریزیم.
- Best\_objective\_plot برای رسم نمودار استفاده شده است که یک لیست است و مقدار ماکسیموم تابع هدف کل جمعیت در هر iteration را ذخیره می‌کند.

```

# MAIN LOOP
iteration = 0
best_objective_plot = []
while iteration < max_iteration:
    summation = sum(object_values)
    pr = []
    cumulative_pr = []
    for i in range(population_size):
        pr.append(object_values[i] / summation)
    cumulative_pr.append(pr[0])
    for i in range(1, population_size - 1):
        temp = cumulative_pr[i - 1] + pr[i]
        cumulative_pr.append(temp)
    cumulative_pr.append(1)

    # CROSS OVER
    for i in range(0, num_crossover, 2):
        . . .

    # MUTATION
    for i in range(num_mutation):
        . . .

```

```

best_objective = max(object_values)
best_arg = np.argmax(object_values)
best_chromosome = population[best_arg]

if len(population) > max_pop_size:
    temp_population = []
    temp_objective = []
    args = np.argsort(object_values)
    for i in range(max_pop_size):
        temp = len(population) - 1 - i
        temp_population.append(population[args[temp]])
        temp_objective.append(object_values[args[temp]])

    population = temp_population
    object_values = temp_objective
    population_size = max_pop_size

#print(best_objective)
best_objective_plot.append(best_objective)
if (best_objective == graph.e):
    break

iteration = iteration + 1

print(best_chromosome)
print(best_objective)

```

- در انتها نیز بهترین عضو و مقدار تابع هدفش را چاپ می‌کنیم.

#### 4. الگوریتم Cross Over:

- دو بخش دارد:
  - انتخاب اعضای برگزیده برای کراس اور
  - اجرای عمل کراس اور
- برای انتخاب اعضای برگزیده کراس اور با توجه به تعداد کراس اور مجاز هر مرحله دوتا دوتا تصادفی جدا می‌کنیم و به تابع cross\_over می‌دهیم. خروجی تابع cross\_over دوتا children خواهد بود.

```

# CROSS OVER
for i in range(0, num_crossover, 2):
    p1 = 0
    temp = np.random.rand()

```

```

while cumulative_pr[p1] < temp:
    p1 = p1 + 1
p2 = p1
while p1 == p2:
    temp = np.random.rand()
    p = 0
    while cumulative_pr[p] < temp:
        p = p + 1
    p2 = p
parent1 = population[p1]
parent2 = population[p2]

children = cross_over(parent1, parent2)

child1 = children[0]
child2 = children[1]

population.append(child1)
object_values.append(objective(child1))


population.append(child2)
object_values.append(objective(child2))

```


- تابع cross\_over به عنوان ورودی دو parent میگیرد و به عنوان خروجی دو children میدهد.
- در ابتدا دو عدد تصادفی تولید میکنیم اگر دو عدد تصادفی یکسان بودند دوباره تولید میکنیم و به صورتی که temp1 کوچکتر از temp2 باشد.
- اما روش ترکیب ما به چه صورت است؟
  - فرض کنید  $n=4$  باشد و دو parent به صورت زیر باشد:




- حال با کمک تولید تصادفی  $temp1 = 1$  و  $temp2 = 2$  بدست آوردیم.




- حال میخواهیم فرزندان اول را بسازیم. از parent1، عنصرهای  $temp1$  تا  $temp2$  را نگه میداریم.



○ و از parent2 به ترتیب آنهایی که استفاده نشده اند را قرار میدهیم.



○ برای این کار یک آرایه با نام removed استفاده میکنیم و اندیس هایی که عددش در child1 استفاده شده است را 1 میگذاریم و باقی 0 میماند.



○ به طور مشابه همین کار را برای child2 انجام میدهیم و آن را تولید میکنیم.



```

def cross_over(parent1, parent2):
    temp1 = np.random.randint(n)
    temp2 = np.random.randint(n)
    while (temp1==temp2):
        temp1 = np.random.randint(n)
        temp2 = np.random.randint(n)
    if temp2 < temp1:
        temp1,temp2 = temp2,temp1

    # CREATE CHILD 1
    child1 = np.zeros(n,dtype=int)
    removed = child1.copy()
    for i in range(temp1, temp2+1):
        child1[i] = parent1[i]
        removed[parent1[i]-1] = 1

    i = 0
    j = 0
    while i < n and j < n:
        if i >= temp1 and i <= temp2:
            i = i + 1
            continue
        while j < n and removed[parent2[j]-1]:
            j = j + 1
        if j == n:
            break

        child1[i] = parent2[j]
        i = i + 1
        j = j + 1

    #CREATE CHILD 2
    child2 = np.zeros(n,dtype=int)
    removed = child2.copy()
    for i in range(temp1, temp2 + 1):
        child2[i] = parent2[i]
        removed[parent2[i]-1] = 1

    i = 0
    j = 0
    while i < n and j < n:
        if i >= temp1 and i <= temp2:
            i = i + 1
            continue

```

```

while j < n and removed[parent1[j]-1]:
    j = j+ 1
if j == n:
    break

child2[i] = parent1[j]
i = i + 1
j = j + 1

return (child1, child2)

```

#### 5. الگوریتم Mutation:

- الگوریتم جهش به این صورت است دو عدد تصادفی تولید میکنیم و در عضو برگزیده شده برای جهش جابه جایش میکنیم. البته یک شرط گذاشتم که همواره جهش به سمت بهتر شدن نیز برود و اگر عدد تصادفی تولید شده باعث بدتر شدن وضعیت میشد عوضش کند.

```

# MUTATION
for i in range(num_mutation):
    temp = np.random.randint(num_crossover)
    temp = temp + population_size
    mutated = population[temp]

    # MUTATION -> shuffle 2 places
    temp = np.random.randint(n)
    temp2 = np.random.randint(n)
    while ((graph.isReachable(mutated[temp],mutated[temp2]) and temp<temp2)):
        temp = np.random.randint(n)
        temp2 = np.random.randint(n)

    mutated[temp] , mutated[temp2] = mutated[temp2] , mutated[temp]

    population.append(mutated)
    object_values.append(objective(mutated))

```

### بخش چهارم - نمودار همگرایی:

- برای این بخش از کتاب خانه matplotlib استفاده کردم.
- برای اضافه کردن این کتابخانه ابتدا دو پکیج زیر را نصب کنید:

```
python -m pip install -U pip
python -m pip install -U matplotlib
```

- سپس pyplot را اضافه میکنیم.

```
import matplotlib.pyplot as plt
```

- همانطور که در بدنه اصلی حلقه گفتیم، Best\_objective\_plot برای رسم نمودار استفاده شده است که یک لیست است و مقدار ماکسیموم تابع هدف کل جمعیت در هر iteration را ذخیره می‌کند.


```
plt.plot(best_objective_plot)
plt.show()
```

- در نمودار محور x ها تعداد iteration ها است و محور y ها مقدار تابع هدف ماکسیموم است.

### بخش پنجم - چند نمونه خروجی:


- خروجی 1:

```
[20  1  3  4  2 10 19 18  8 17 16 15  7 11 12  6 13  9 14  5]
54
```



- خروجی 2:

```
[20 2 3 1 4 10 8 19 18 17 16 15 11 7 6 12 13 9 14 5]  
54
```



### بخش ششم – مقایسه با الگوریتم SA:

- با توجه به الگوریتمی که من نوشتم الگوریتم SA در این مسئله خاص سریع تر است. شاید مقدار iteration الگوریتم ژنتیک در جمعیت های زیاد کمتر باشد ولی محاسباتش پیچیده تر و هزینه بر تر است. برای مسئله های پیچیده تر الگوریتم ژنتیک میتواند به شدت سریع تر باشد و به جواب برسد ولی الگوریتم SA ممکن است مسیر اشتباه بیافتد.
- مورد بعدی که به چشم من خورد خطای کمتر الگوریتم ژنتیک نسبت به SA است. الگوریتم ژنتیک در اجرا های مختلف همواره به جواب درست رسید. اما الگوریتم SA کمتر به جواب درست میرسید. (البته اندازه جمعیت در این مورد تاثیر گذار است).